Parcial: Reproducción y extensión de un artículo científico con Machine Learning clásico

1. Propósito

Cada estudiante reproduce total o parcialmente un artículo publicado que aplica Machine Learning clásico (sin Deep Learning) a un problema de física o de síntesis de nanopartículas. Luego identifica un vacío de conocimiento (gap) y propone y ejecuta un trabajo nuevo con esos mismos datos.

2. Objetivos de aprendizaje

Al finalizar, el estudiante debe ser capaz de:

- Leer críticamente un artículo científico e identificar su pregunta, sus datos, su metodología y sus limitaciones.
- Reconstruir un flujo de trabajo de ML a partir de la descripción de un paper: preprocesamiento, selección de variables, entrenamiento, validación y métricas.
- Comparar sus resultados con los publicados y explicar las diferencias.
- Formular una pregunta de investigación nueva y viable a partir de un gap.
- Comunicar resultados de forma reproducible, con código, datos y un informe tipo artículo.

3. Selección del artículo

1. **Banco de artículos:** el estudiante escoge un artículo de la lista oficial del curso (archivo papers).
2. **Un artículo por estudiante:** no se repiten. La asignación se hace mediante una elección individual.
3. **Verificar los datos antes de inscribirse:** el estudiante debe confirmar que puede descargar los datos. La columna "Tipo de acceso a datos" orienta:
    - **Enlace directo:** datos listos para descargar. Es la opción recomendada.
    - **Material suplementario:** los datos están en el SI del artículo. Hay que revisar que estén completos.
4. **Base pública:** los datos vienen de una base grande (Fermi, Gaia, Kepler, OMNI). Requieren más preprocesamiento .
5. **Cambio de artículo:** si después de la inscripción los datos resultan inaccesibles, el estudiante puede cambiar de artículo una sola vez, siempre y cuando el nuevo articulo ya no se encuentre seleccionado por ningun otro estudiante.

4. Actividades

Parte A: Propuesta (1 diapositiva)

Entregar un documento corto con:

- La referencia completa del artículo y el enlace a los datos.
- La pregunta científica del paper y por qué es relevante, en 3 a 5 líneas.

- Qué resultado(s) del paper se van a reproducir: tabla, figura o métrica específica.
- Una primera idea del gap que se piensa explorar.
- Una descripción breve de los datos: número de muestras, variables y variable objetivo.

Parte B: Reproducción del artículo

El estudiante debe reproducir al menos un resultado cuantitativo central del paper.

Qué se acepta como reproducción

- **Total:** se replica el flujo completo y las métricas principales del artículo.
- **Parcial:** se reproduce un subconjunto bien delimitado, por ejemplo uno de los modelos, una de las variables objetivo o una de las figuras principales. El alcance debe justificarse en la propuesta.

Qué debe incluir

1. **Datos:** descripción del dataset, limpieza y preprocesamiento. Si el paper no detalla algún paso, el estudiante debe tomar una decisión y documentarla como supuesto.
2. **Modelos:** implementación de los mismos algoritmos clásicos del paper (Random Forest, XGBoost, SVM, regresión logística, procesos gaussianos, etc.) con hiperparámetros iguales o lo más cercanos posible.
3. **Validación:** el mismo esquema del paper (partición train/test, validación cruzada, etc.).
4. **Comparación:** una tabla con las métricas del paper frente a las obtenidas (R^2, RMSE, MAE, accuracy, AUC, TSS, según el caso).
5. **Análisis de discrepancias:** si los resultados no coinciden, explicar las posibles causas: datos distintos, hiperparámetros no reportados, semillas aleatorias, versiones de librerías, preprocesamiento ambiguo.

No reproducir exactamente el resultado no implica perder la nota. Se evalúa la rigurosidad del intento y la calidad del análisis de las diferencias.

Parte C: Identificación del gap de conocimiento

A partir de la lectura crítica del paper y de la experiencia de reproducirlo, el estudiante identifica un vacío concreto que pueda abordarse con los mismos datos. Debe argumentar:

- Qué no respondió el artículo, o qué respondió de forma limitada.
- Por qué es relevante para la física o la química del problema.
- Por qué es viable con el dataset disponible.

Tipos de gap válidos (ejemplos orientativos)

- **Interpretabilidad:** aplicar SHAP, importancia por permutación o dependencia parcial y contrastar con la física del problema.
- **Comparación de algoritmos:** comparar varios algoritmos clásicos con validación estadística (validación cruzada repetida con prueba de significancia).
- **Incertidumbre:** cuantificarla con procesos gaussianos, regresión cuantílica o bootstrap.

- **Generalización:** evaluar la extrapolación con particiones por grupo, por rango de la variable objetivo o por tiempo.
- **Eficiencia de datos:** construir curvas de aprendizaje y explorar aprendizaje activo o selección de muestras informativas.
- **Desbalance de clases:** comparar sobremuestreo, submuestreo o pesos de clase.
- **Ingeniería de variables:** construir variables con significado físico (cocientes, números adimensionales, descriptores químicos) y evaluar si mejoran el modelo.
- **Diseño inverso:** usar el modelo entrenado para proponer condiciones de síntesis o configuraciones que alcancen un objetivo, en especial en los papers de nanopartículas.
- **Reformulación del problema:** convertir una regresión en clasificación o viceversa, o predecir una variable que el paper no modeló.

Parte D: Nuevo trabajo

El estudiante diseña y ejecuta un estudio que responda al gap identificado.

- **Mismos datos:** se trabaja con el dataset del paper. Se permiten subconjuntos, transformaciones y nuevas variables derivadas de él. No se permiten datos externos sin autorización del docente.
- **Solo ML clásico:** no se permite Deep Learning (redes neuronales profundas, CNN, transformers, etc.). Sí se permiten SHAP, optimización bayesiana o ensambles de modelos clásicos.
- **Hipótesis explícita:** formulada antes de los experimentos y contrastada con los resultados.
- **Comparación con la reproducción:** la reproducción de la Parte B sirve como línea base.
- **Discusión física o química:** los resultados se interpretan en términos del fenómeno estudiado, no solo de métricas.

5. Entregables

1. **Propuesta:** 1 diapositiva, en la fecha indicada en el cronograma.
2. **Código reproducible** en un repositorio (GitHub o similar) con:
    - Notebook(s) o scripts ejecutables de principio a fin.
    - Archivo requirements.txt o equivalente con las versiones de las librerías.
    - Semillas aleatorias fijadas.
    - Un README que explique cómo descargar los datos y ejecutar el análisis.
3. **Sustentación oral:** 20 minutos de presentación y 5 de preguntas.

6. Rúbrica de evaluación

Componente	Peso (%)	Qué se evalúa
Propuesta	10	Claridad del alcance, viabilidad, verificación del acceso a los datos
Reproducción	30	Fidelidad al método original, comparación de métricas, análisis de discrepancias
Identificación del gap	15	Pertinencia, justificación desde la literatura y viabilidad con los datos

Componente	Peso (%)	Qué se evalúa
Nuevo trabajo	25	Diseño experimental, rigor en la validación, interpretación física o química
Código y reproducibilidad	10	El repositorio se ejecuta sin errores y está documentado
Informe y sustentación	10	Redacción, figuras, manejo de preguntas

7. Normas

- **Integridad académica:** todo código o texto tomado de otras fuentes debe citarse. Si el paper tiene código público, se puede consultar, pero la implementación entregada debe ser propia y explicada por el estudiante.
- **Uso de herramientas de IA:** se permite como apoyo, pero debe declararse en un anexo qué se usó y para qué. El estudiante debe poder explicar cada línea de su código en la sustentación.
- **Honestidad en los resultados:** reportar resultados negativos o reproducciones fallidas es válido y se valora. Ajustar el análisis para que coincida con el paper sin justificarlo se penaliza.